

# 11주: 기계학습(1)

---

김 남 규 (ngkim@deu.ac.kr)

## 11주: 기계학습(1)

### 1 학습(learning)

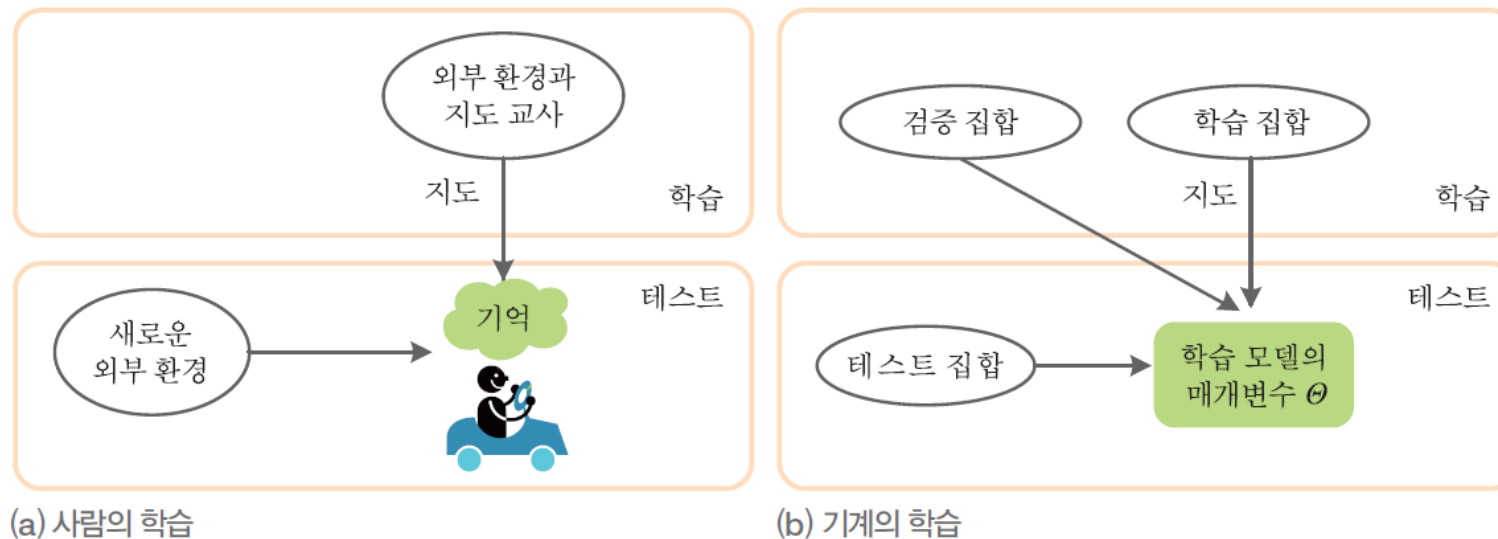
김 남 규 (ngkim@deu.ac.kr)

# 기계 학습(Machine Learning)

- By Mitchell, 1997
  - “A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P, if its performance at tasks in T, as measured by P, improves with experience E.
  - 어떤 컴퓨터 프로그램이 T라는 작업을 수행한다.  
이 프로그램의 성능을 P라는 척도로 평가했을 때  
경험 E를 통해 성능이 개선된다면 이 프로그램은 학습을 한다고 말할 수 있다
- 영상 처리 및 컴퓨터 비전에 대입
  - T = 분류(인식)
  - E = 학습 집합
  - P = 인식률

# 학습 과정

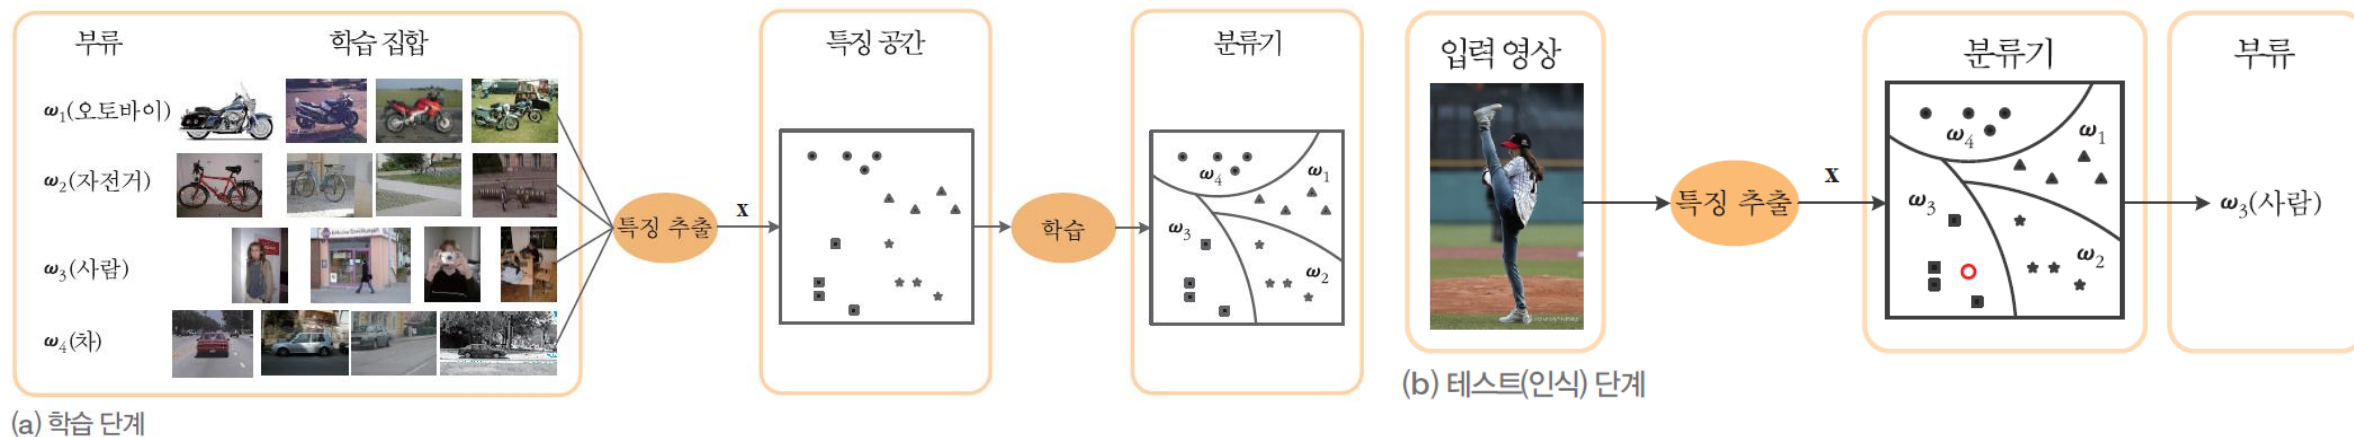
- 학습 단계: 외부 지도에 따라 배우는 과정 (학습 집합 사용)
- 테스트 단계: 현장에서 성능을 평가 하는 과정 (테스트 집합 사용)



- 지도 (Supervised) vs 비지도 (Unsupervised) 학습

# 지도 학습

- 부류 정보를 가진 샘플 ( $x, t$ )로 구성된 학습 집합 사용
- $x$ 는 특징 벡터이고  $t$ 는  $x$ 가 속한 부류
- 입력과 출력간의 관계를 함수로 학습, 예) 필기 숫자 분류, 영상 분류



# 비지도 학습

- 지도 학습에서 사용했던  $(x, t)$  중에 부류 정보  $t$ 가 없는 상황의 학습
- 학습 결과물의 형태를 정확히 알지 못하는 경우, 예) 클러스터링(사전 지식 없음)
- 비지도 학습 예
  - 유사한 특징 벡터들을 끼리끼리 모으는 군집화 수행 (K-means, 신경망, Mean Shift, PCA/Eigenface 등의 군집화 알고리즘)
  - 군집에서 유용한 정보 추출 (데이터 마이닝, 빅데이터, 정보 검색 등의 많은 응용)
- 준지도 학습(Semi-supervised Learning)
  - 부류 정보가 있는 샘플과 없는 샘플이 섞여 있는 상황의 학습
  - 최근 중요성 부각: 아직 부류 정보를 부여하지 못한 샘플이 시시각각 인터넷에서 발생하기 때문
  - 부류 정보가 있는 샘플로 학습한 후 부류 정보가 없는 샘플의 부류 정보를 추정
  - 추정된 정보로 반복 학습


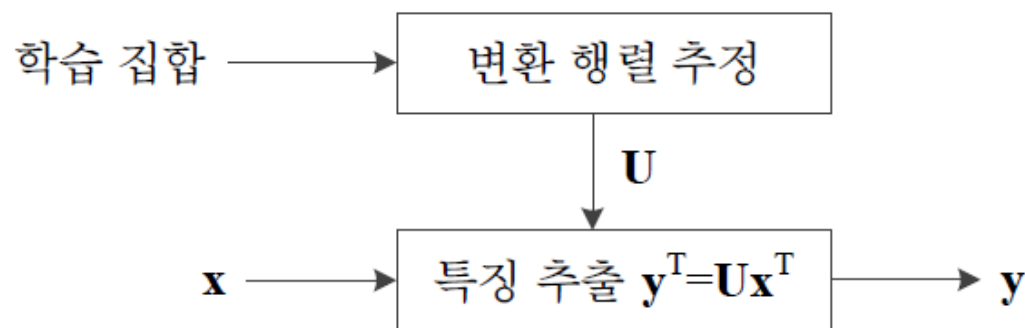
## 11주: 기계학습(1)

# 2 주성분 분석(PCA) & 고유 얼굴(Eigenface)

김 남 규 (ngkim@deu.ac.kr)

# 주성분 분석


- Principle Component Analysis, PCA
- 기본 개념: 고차원의 정보(벡터)를 저차원으로 축소
- 원리
  - 학습 집합  $X = \{x_1, x_2, x_3, \dots, x_n\}$ 로 변환 행렬  $U$ 를 추정
  - $U$ 는  $d \times D$ 로서  $D$ 차원의  $x$ 를  $d$ 차원의  $y$ 로 변환






# 차원의 축소와 정보 손실


- 차원 축소의 표현: 축  $u$  상으로 투영으로 표현  $\hat{x} = \mathbf{u}\mathbf{x}^T$



(a)  $\mathbf{u}=(0,1)$ 로 투영



(b)  $\mathbf{u}=(1,0)$ 으로 투영




(c)  $\mathbf{u}=(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})$ 로 투영


- 정보(점 간의 거리, 상대적 위치 등)의 손실: 손실 최소화 방법?

# PCA의 정보 손실 표현


- 원래 공간에 퍼져 있는 정도를 변환된 공간이 얼마나 잘 유지하는지 측정
- 이 수치를 변환된 공간에서 **분산**으로 측정
- 최적화 문제로 전환: 변환된 샘플들의 분산을 최대화하는 단위 벡터  $\mathbf{u}$ 를 찾아라.



(a)  $\mathbf{u}=(0,1)$ 로 투영



(b)  $\mathbf{u}=(1,0)$ 으로 투영



(c)  $\mathbf{u}=(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})$ 로 투영

# 예 분석

- 원래 샘플

$$\mathbf{x}_1 = (1, 2), \mathbf{x}_2 = (4, 2), \mathbf{x}_3 = (1, 4), \mathbf{x}_4 = (3, 4)$$

- $\mathbf{u} = (0, 1)$ 로 투영 변환된 샘플

$$\hat{x}_1 = (0 \ 1) \begin{pmatrix} 1 \\ 2 \end{pmatrix} = 2, \hat{x}_2 = (0 \ 1) \begin{pmatrix} 4 \\ 2 \end{pmatrix} = 2, \hat{x}_3 = (0 \ 1) \begin{pmatrix} 1 \\ 4 \end{pmatrix} = 4, \hat{x}_4 = (0 \ 1) \begin{pmatrix} 3 \\ 4 \end{pmatrix} = 4$$


투영 변환으로 얻은 네 개의 점 2, 2, 4, 4의 평균은 3이고 분산은 1이다.

- $\mathbf{u} = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$ 로 투영 변환된 샘플

$$\hat{x}_1 = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right) \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \frac{3}{\sqrt{2}}, \hat{x}_2 = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right) \begin{pmatrix} 4 \\ 2 \end{pmatrix} = \frac{6}{\sqrt{2}},$$

$$\hat{x}_3 = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right) \begin{pmatrix} 1 \\ 4 \end{pmatrix} = \frac{5}{\sqrt{2}}, \hat{x}_4 = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right) \begin{pmatrix} 3 \\ 4 \end{pmatrix} = \frac{7}{\sqrt{2}}$$

이들의 평균은 3.7123이고 분산은 1.0938이다.  $\mathbf{u} = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$ 이  $\mathbf{u} = (0, 1)$ 보다 큰 분산을 만들어 준다. PCA가 볼 때  $\mathbf{u} = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$ 이 더 좋은 것이다. 그렇다면 [그림 6-22]의 상황에서  $\mathbf{u} = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$ 보다 더 좋은 축이 있을까? 이것에 대한 답이 바로 식 (6.34) 문제의 해이다.



# 수학적 배경

$$\hat{x}_i, 1 \leq i \leq n \text{의 평균 } \bar{\hat{x}} = \frac{1}{n} \sum_{i=1}^n \hat{x}_i = \frac{1}{n} \sum_{i=1}^n \mathbf{u} \mathbf{x}_i^T = \mathbf{u} \left( \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i^T \right) = \mathbf{u} \bar{\mathbf{x}}^T$$

$$\hat{x}_i, 1 \leq i \leq n \text{의 분산 } \hat{\sigma} = \frac{1}{n} \sum_{i=1}^n (\hat{x}_i - \bar{\hat{x}})^2 = \frac{1}{n} \sum_{i=1}^n (\mathbf{u} \mathbf{x}_i^T - \mathbf{u} \bar{\mathbf{x}}^T)^2$$

- 단위 벡터 가정:  $L(\mathbf{u}) = \frac{1}{n} \sum_{i=1}^n (\mathbf{u} \mathbf{x}_i^T - \mathbf{u} \bar{\mathbf{x}}^T)^2 + \lambda (1 - \mathbf{u} \mathbf{u}^T)$ 를 최대화하는  $\mathbf{u}$ 를 찾아라.

$$\frac{\partial L(\mathbf{u})}{\partial \mathbf{u}} = \partial \left( \frac{1}{n} \sum_{i=1}^n (\mathbf{u} \mathbf{x}_i^T - \mathbf{u} \bar{\mathbf{x}}^T)^2 + \lambda (1 - \mathbf{u} \mathbf{u}^T) \right) / \partial \mathbf{u}$$

$$= \frac{2}{n} \sum_{i=1}^n (\mathbf{u} \mathbf{x}_i^T - \mathbf{u} \bar{\mathbf{x}}^T) (\mathbf{x}_i - \bar{\mathbf{x}}) - 2\lambda \mathbf{u}$$

$$= 2\mathbf{u} \left( \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})^T (\mathbf{x}_i - \bar{\mathbf{x}}) \right) - 2\lambda \mathbf{u}$$

$$= 2\mathbf{u} \Sigma - 2\lambda \mathbf{u}$$

$$= 2\Sigma \mathbf{u}^T - 2\lambda \mathbf{u}$$

$$\Sigma \mathbf{u}^T = \lambda \mathbf{u}^T \quad \Sigma \text{는 훈련 집합의 공분산 행렬}$$

$$\begin{matrix} & \begin{matrix} x & y & z \end{matrix} \\ \begin{matrix} x \\ y \end{matrix} & \begin{bmatrix} \text{var}(x) & \text{cov}(x, y) \\ \text{cov}(x, y) & \text{var}(y) \end{bmatrix} \end{matrix} \quad \begin{matrix} x & y & z \\ \begin{bmatrix} \text{var}(x) & \text{cov}(x, y) & \text{cov}(x, z) \\ \text{cov}(x, y) & \text{var}(y) & \text{cov}(y, z) \\ \text{cov}(x, z) & \text{cov}(y, z) & \text{var}(z) \end{bmatrix} \end{matrix}$$

$$\text{var}(x) = \frac{\sum_i^n (x_i - \mu)^2}{N}$$

$$\text{cov}(x, y) = \frac{\sum_i^n (x_i - \mu) \cdot (y_i - \mu)}{N}$$

# PCA 기초 알고리즘

- 학습 집합의 공분산 행렬 계산 → 공분산 행렬의 고유 벡터 계산

- 원래 샘플

$$\mathbf{x}_1 = (1, 2), \mathbf{x}_2 = (4, 2), \mathbf{x}_3 = (1, 4), \mathbf{x}_4 = (3, 4)$$

- 공분산 행렬 :  $\Sigma = \begin{pmatrix} 1.688 & -0.250 \\ -0.250 & 1.000 \end{pmatrix}$

- 고유값과 고유 벡터 :

$$\lambda_1 = 1.7688, \mathbf{u}_1 = (0.9510, -0.3092)$$

$$\lambda_2 = 0.9187, \mathbf{u}_2 = (-0.3092, -0.9510)$$


두 개의 고유 벡터 중에 고유값이 큰  $\mathbf{u}_1$ 을 선택한다. 이  $\mathbf{u}_1$ 에 네 점을 투영한 결과는 다음과 같다.

- $\mathbf{u}_1 = (0.9510, -0.3092)$ 로 투영된 특징 벡터 :

$$\hat{x}_1 = (0.9510 \ -0.3092) \begin{pmatrix} 1 \\ 2 \end{pmatrix} = 0.3326, \quad \hat{x}_2 = (0.9510 \ -0.3092) \begin{pmatrix} 4 \\ 2 \end{pmatrix} = 3.1856$$

$$\hat{x}_3 = (0.9510 \ -0.3092) \begin{pmatrix} 1 \\ 4 \end{pmatrix} = -0.2858, \quad \hat{x}_4 = (0.9510 \ -0.3092) \begin{pmatrix} 3 \\ 4 \end{pmatrix} = 1.6162$$


투영 변환된 점들의 평균은 1.2122이고 분산은 1.7688이다.



# D 차원에 적용

- 공분산 행렬  $\Sigma$ 는  $D \times D$ 이므로,  $D$ 개의 고유 벡터가 있음
- 이들은 서로 수직인 단위 벡터, 즉  $\mathbf{u}_i^T \mathbf{u}_j = 1$ 이고  $\mathbf{u}_i^T \mathbf{u}_j = 0, i \neq j$
- 고유값이 큰 순서대로 상위  $d$ 개의 고유 벡터  $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_d$ 를 선택, ( $\mathbf{U}$ 는  $d \times D$ )
- $\mathbf{U}$ 를 이용한 차원 축소  $\mathbf{y}^T = \mathbf{U}\mathbf{x}^T$

$$\mathbf{U} = \begin{pmatrix} \mathbf{u}_1 \\ \mathbf{u}_2 \\ \vdots \\ \mathbf{u}_d \end{pmatrix}$$



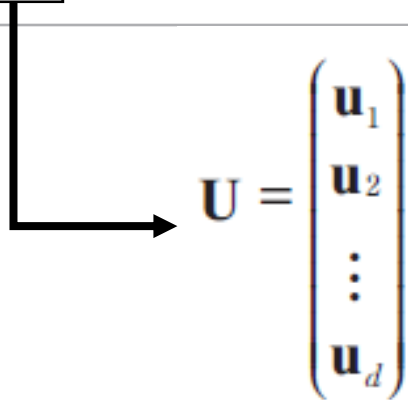
$$\lambda_1 = 1.7688, \mathbf{u}_1 = (0.9510, -0.3092)$$
$$\lambda_2 = 0.9187, \mathbf{u}_2 = (-0.3092, -0.9510)$$

# PCA에 의한 특징 추출

입력 : 학습 집합  $X = \{x_1, x_2, \dots, x_n\}$ , 원하는 차원  $d$

출력 : 변환 행렬  $U$ , 평균 벡터  $\bar{x}$

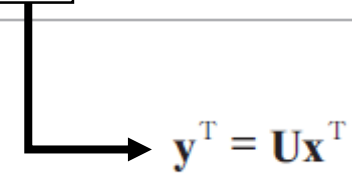
- 1  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$  //  $X$ 의 평균 벡터  $\bar{x}$ 를 구한다.
- 2 for( $i=1$  to  $n$ )  $x'_i = x_i - \bar{x}$  ; // 모든 샘플을 원점 중심으로 옮긴다.
- 3  $x'_i, 1 \leq i \leq n$ 의 공분산 행렬  $\Sigma$ 를 구한다.
- 4  $\Sigma$ 의 고유 벡터와 고유값을 구한다.
- 5 고유값 기준으로 상위  $d$ 개의 고유 벡터를 선택하고, 이들을  $u_1, u_2, \dots, u_d$ 라 하자.
- 6 식 에 따라 변환 행렬  $U$ 를 만든다.


$$U = \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_d \end{pmatrix}$$

입력 : 변환 행렬  $U$ , 평균 벡터  $\bar{x}$ , 벡터  $x$


출력 : 변환된 벡터  $y$

- 1  $x = x - \bar{x}$  ; // 샘플을 원점 중심으로 옮긴다.
- 2 식 로  $y$ 를 구한다.


$$y^T = Ux^T$$

# 고유 얼굴

- 얼굴 영상에 PCA 적용
- 영상  $f_i$ 를 벡터 형태로 변환 (벡터의 차원  $D=MN$ ): 행 우선으로 재배치
$$\mathbf{x}_i = (f_i(0,0), f_i(0,1), f_i(0,2), \dots, f_i(0,N-1), f_i(1,0), f_i(1,1), \dots, f_i(M-1,N-1))$$
- $n$ 개의 얼굴 영상으로 구성된 학습 집합  $X = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ 을 입력으로 PCA를 적용
- 고유 벡터  $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_d$ 를 고유 얼굴이라 부름



$$\mathbf{x}'^T = \mathbf{U}^{-1} \mathbf{y}^T$$

고유값이 작아짐



# 고유 얼굴을 활용한 얼굴 인식

- 고유 얼굴의 활용: 얼굴 인식, Turk, 1991
  - PCA로 변환한 벡터  $y_i$ 를 모델로 사용:  $Y = \{y_1, y_2, \dots, y_n\}$
  - 테스트 영상  $f$ 가 입력되면 PCA로  $y$ 를 구한 후,  $Y$ 에서 가장 가까운 벡터를 찾아 그 부류로 분류
- 고유 얼굴 활용 시 주의 점
  - 얼굴을 찍은 각도와 얼굴 크기, 영상 안에서의 얼굴 위치, 조명이 어느 정도 일정해야 함.
  - 영상마다 다르고 그 변화가 클수록 성능이 떨어짐
  - 조명에 변화를 준 경우 96%, 각도에 변화를 준 경우 85%, 크기에 변화를 준 경우 64%의 인식률을 얻음

## 11주차 : 기계학습(1)



본 강의 자료의 내용 및 그림은 아래 책으로부터 발췌 되었음

- 파이썬으로 배우는 영상처리, Sandipan Dey 지음, 정성환, 조보호, 배종욱 옮김, 도서출판 홍릉, 2020년
- Digital Image Processing, 4<sup>th</sup> Ed., Rafael C. Gonzalez, Richard E. Woods 지음, Pearson, 2018년
- 컴퓨터 비전(Computer Vision) 기본 개념부터 최신 모바일 응용 예까지 IT CookBook, 오일석 지음, 한빛아카데미, 2014년

김 남 규 (ngkim@deu.ac.kr)